RL-дообучение последовательной рекомендательной модели

Отчёт по заданию T-Lab 2026, RecSys, задание 2. Датасет — KION от МТС.

Содержание

- Коротко: что сделано и что получилось
- Постановка
- Данные и разбиение
- Почему здесь нет утечек
- Базовая модель
- Модели вознаграждения
- Метод RL
- Что на самом деле выучила модель вознаграждения
- Второй сигнал: возвращается ли пользователь
- Что сделало RL
- Вознаграждение растёт, ценность падает
- Подпись взлома reward-модели
- Почему схлопывание было предсказуемо
- Рисунки
- Компромисс между релевантностью и вознаграждением
- Это не шум
- Стандартные для RLHF значения KL здесь не работают
- Жадная оптимизация вознаграждения без ограничения
- Что меняется в поведении модели
- Многошаговая генерация
- Долгосрочные цели
- Что можно проверить офлайн, а что нельзя
- Ограничения
- Воспроизведение
- Структура репозитория

Коротко: что сделано и что получилось

Базовая модель — GPT-2 (2.8 млн параметров) на next item prediction по KION, токены это идентификаторы контента. Две модели вознаграждения: доля досмотра и возврат пользователя в течение недели. Дообучение — GRPO со штрафом KL к замороженной исходной политике. Разбиение по времени, тестовые две недели читаются один раз, шесть автотестов на утечки.

Главный результат: максимизировать вознаграждение легко, и именно это опасно. Наивная оптимизация поднимает предсказанное вознаграждение на 25% и при этом снижает реально доставленное время просмотра на 12%. Полезный режим существует, но он узкий, и находится там, где штраф KL на два порядка сильнее принятого в RLHF.

Итог на тесте, 20 000 пользователей:

подход	NDCG@10	обещанная награда	доставлено на пользователя
RL, KL = 2	0.1207	0.555	**0.2259** (+2.9%)
RL, KL = 5	0.1237	0.531	0.2239
базовая GPT-2	**0.1252**	0.503	**0.2195**
RL, KL = 0	0.0934	0.630	0.1937 (−12%)
популярность	0.0911	0.507	0.1568
best-of-50 по вознаграждению	0.0534	0.670	0.1491 (−32%)
RL на сигнале возврата	0.0177	0.633	0.0475 (−78%)
десять самых досматриваемых	0.0077	**0.779**	0.0258 (−88%)

Таблица читается снизу вверх: **чем выше обещанное вознаграждение, тем ниже доставленная ценность.** Оптимум модели вознаграждения — это список-константа из десяти позиций, одинаковый для всех.

Шесть вещей, которые стоит прочитать, даже если дальше читать не хочется.

1. Наивная метрика врёт, и я поймал это на себе. Среднее вознаграждение по попавшим рекомендациям росло всё обучение — с 0.504 до 0.568, выглядело как успех. Но его знаменатель сокращается вместе с числом попаданий, с 2586 до 1957: политика, рекомендующая мало, но «безопасно», выглядит лучше, чем она есть. С фиксированным знаменателем — доставлено на пользователя — та же кривая растёт до 50-го шага, а потом падает на 15%.

2. Взлом reward-модели измерен, а не заявлен. Разрыв между обещанным и наблюдаемым вознаграждением вырос с −0.003 в начале до +0.059 к 300-му шагу, монотонно. Видно это только потому, что наблюдаемое считается на отложенных данных; по тому числу, которое оптимизирует RL, кривая выглядит ровным успехом до самого конца.

3. Схлопывание было предсказано до эксперимента. Диагностика показала, что 70% дисперсии модели вознаграждения объясняется айтемом и лишь 30% — персонализацией. Отсюда следовало, что политика поедет к глобально досматриваемому контенту. Покрытие каталога упало с 8.9% до 3.7%.

4. Стандартные для RLHF коэффициенты KL здесь занижены на два порядка. Весь диапазон 0.01–0.1 лежит в области схлопывания. Рабочая область — от 1 до 5. Причина структурная: у языковой модели уйти далеко мешает сама грамматика, у рекомендателя любой из 15 706 айтемов — допустимое продолжение.

5. Тривиальное переранжирование оказалось хуже RL, а не лучше. Я ожидал обратного. Best-of-50 по модели вознаграждения поднимает обещанную награду выше любого прогона RL и при этом роняет NDCG на 57%. Ценность RL здесь не в оптимизации вознаграждения — она в том, что штраф KL даёт регулируемый способ забрать часть выигрыша, не уходя далеко.

6. Долгосрочная цель в наивной формулировке даёт катастрофу. Сигнал «вернулся за неделю» независим от доли досмотра (корреляция −0.002) и персонализируется в десять раз лучше — казалось бы, идеальная цель. RL против него обрушил NDCG в семь раз. Причина: возврат определяется в основном активностью самого пользователя, а не рекомендацией, и градиент политики от такого сигнала не получает полезного направления. Сигнал, который хорошо **предсказывается**, не обязан быть сигналом, который хорошо **оптимизируется**.

Постановка

Задание предлагает три шага: обучить GPT-2 на next item prediction, построить модель вознаграждения, дообучить рекомендатель с помощью RL — и разобраться, что при этом происходит с поведением модели.

Главная сложность не в том, чтобы поднять предсказанное вознаграждение. Поднять его легко. Сложность в том, чтобы отличить настоящее улучшение от эксплуатации ошибок модели вознаграждения, и чтобы это отличие было **измерено**, а не заявлено. Вся конструкция этой работы построена вокруг такого измерения.

Данные и разбиение

KION: 5 476 251 просмотр, 15 706 единиц контента, 962 179 пользователей, период с 13 марта по 22 августа 2021 года. Токены — идентификаторы айтемов, плюс два служебных (`PAD`, `BOS`), итого словарь 15 708.

Разбиение по времени, одно и то же для всех этапов:

часть	период	назначение
обучение	до 2 августа	базовая модель, обе reward-модели, промпты для RL
валидация	2–9 августа	ранняя остановка, выбор коэффициента KL, наблюдение за RL
тест	9–22 августа	единственный финальный замер

Пользователей с историей не меньше пяти событий до 2 августа — 240 275; из них 58 813 имеют целевые события на валидационной неделе и 77 009 на тестовых.

Ограничение, которое стоит назвать сразу. Таймстемпы в KION дневные, и 30.2% пользовательских дней содержат больше одного события (в среднем 2.84). То есть примерно треть порядка внутри «последовательности» принципиально неизвестна. Внутри дня события упорядочены по идентификатору айтема — это воспроизводимо, но произвольно. Для последовательной модели это существенный шум, и его надо держать в уме при чтении любых цифр ниже.

Второе свойство датасета, меняющее постановку. В таблице взаимодействий ровно одна строка на пару (пользователь, айтем): повторных просмотров нет вообще. Поэтому классический способ взлома reward-модели — «рекомендовать уже знакомое, оно точно понравится» — здесь невозможен, и уже просмотренное исключается из ранжирования как гарантированно неверное. Ломаться модель будет иначе, и как именно — отдельный вопрос этой работы.

Почему здесь нет утечек

В последовательных моделях утечка прячется тише, чем в признаковых пайплайнах: целевой айтем может попасть в собственный контекст, reward-модель может увидеть то самое событие, отклик на которое предсказывает, а промпты для RL могут оказаться взяты из недель, отведённых под оценку. Все три случая проверяются напрямую на тех тензорах, которые получает обучение (`tests/test_no_leakage.py`, шесть тестов):

1. **Обучающие окна заканчиваются на срезе.** Ни одно окно базовой модели не содержит событий после 2 августа.

2. **Reward-модель не видит своей цели.** В истории примера нет того айтема, отклик на который она предсказывает.
3. **Валидация и тест берутся из своих окон.** Примеры для каждой части приходят только из её периода.
4. **Контекст оценки не содержит целевых айтемов.**
5. **Отравление будущим.** Добавление синтетических событий в конец каждой последовательности обязано оставить обучающие окна и контексты оценки побитово теми же.
6. **Уже просмотренное исключается из ранжирования.** Иначе модель получала бы баллы за повторение того, что повториться не может.

Базовая модель

GPT-2 (`GPT2LMHeadModel` из transformers), 4 слоя, 4 головы, скрытая размерность 128, контекст 32 айтема, 2.8 млн параметров. Обучение — обычный причинный языковой лосс, батчи собираются по длине истории, потому что медиана длины 9, и паддинг до 32 стоил бы втрое дороже.

Модели вознаграждения

Доля досмотра. Предсказывает `watched_pct / 100` для пары (история, кандидат). Трансформерный ствол читает историю, последнее скрытое состояние соединяется с эмбеддингом кандидата, и их поэлементное произведение подаётся в голову — ответ зависит от совпадения истории и кандидата, а не от каждого по отдельности.

Рядом измеряются два baseline'а, и это не формальность. Если модель не обходит «среднее по айтему», значит она выучила не отклик пользователя, а популярность айтема под другим именем, и весь дальнейший RL оптимизировал бы не то, что заявлено.

Возврат в сервис. Вторая модель предсказывает другой сигнал: было ли у пользователя хоть одно событие в течение семи дней после этого. Это не удержание в строгом смысле, а его офлайн-прокси, но единственный долгосрочный вопрос, на который дневные таймстемпы KION отвечают честно.

Метод RL

GRPO. Для каждого контекста политика сэмплирует группу из восьми кандидатов, reward-модель их оценивает, преимуществом каждого служит его награда минус среднее по собственной группе, нормированное на разброс внутри группы. Критик не нужен — на ноутбуке это решающее соображение.

Штраф KL считается к замороженной стартовой политике и **по всему распределению айтемов**, а не только по сэмплированным: вся тревога как раз в том, что масса тихо перетекает к десятку популярных позиций, и по сэмплам это видно хуже. Коэффициент KL — главный исследуемый параметр.

Что на самом деле выучила модель вознаграждения

Прежде чем что-либо оптимизировать, стоит понять, что именно оптимизируется. Модель доли досмотра сравнивается с двумя baseline'ами на валидационной неделе (200 000 примеров):

предсказатель	MAE	RMSE	Spearman	AUC (досмотр ≥ 0.5)
среднее по всем событиям	0.3753	0.4028	—	0.500
среднее по айтему, сглаженное	0.3332	0.3771	+0.352	0.674
обученная модель	0.3225	0.3716	+0.372	0.683

Модель обходит справочник «среднее по айтему» всего на 0.02 по Spearman и на 0.009 по AUC. Это заставляет задать прямой вопрос: а есть ли в ней персонализация вообще, или это тот же справочник с лишними шагами?

Ответ — есть, но немного. Разложение предсказаний на валидации:

показатель	значение
корреляция предсказаний со справочником по айтему	0.878
разброс предсказаний между айтемами	0.159
разброс предсказаний для одного айтема между пользователями	0.069
доля персонализации в общем разбросе	30%
Spearman остатка (предсказание минус справочник) с остатком отклика	**+0.131**

Последняя строка важнее остальных. Если бы модель была чистым справочником, остаток после вычитания средней по айтему не предсказывал бы ничего, и Spearman остатка был бы около нуля. Он равен +0.131 — персонализация настоящая, просто её примерно втрое меньше, чем общей «досматриваемости» контента.

Из этого следует проверяемое предсказание о том, что сделает RL. Если 70% сигнала вознаграждения — это свойство айтема, а не пары, то политика, максимизирующая это вознаграждение, будет двигаться не в сторону лучшей персонализации, а в сторону глобально досматриваемого контента: то есть схлопываться к узкому набору позиций, одинаковому для всех. Персонализирующая треть даст слабый противоток.

Предсказание сформулировано до запуска RL; что с ним стало — в разделе результатов.

Второй сигнал: возвращается ли пользователь

Доля досмотра — сигнал внутри одного контакта. О том, останется ли человек в сервисе, он не говорит ничего, и это не предположение, а измеримый факт. На тех же данных корреляция между «досмотрел не меньше половины» и «вернулся в течение семи дней» составляет **0.097**.

Два почти независимых сигнала означают, что максимизация доли досмотра не приближает к долгосрочной цели сама по себе: она движет модель вдоль оси, почти ортогональной удержанию. Поэтому обучена вторая модель вознаграждения — на событие «у пользователя была хоть одна активность в следующие семь дней». Базовая частота такого события 64.7%.

Это, разумеется, прокси, а не удержание: событие через неделю могло случиться по множеству причин, не связанных с конкретной рекомендацией, и офлайн отличить их нельзя. Что здесь действительно проверяемо — изменится ли поведение политики, если вести её по другому сигналу. Что требует онлайна — вопрос о том, вырастет ли удержание на самом деле.

Что сделало RL

Вознаграждение растёт, ценность падает

Прогон без KL-штрафа, 300 шагов GRPO, 6000 пользователей валидации:

шаг	NDCG@10	покрытие	предсказанная награда	наблюдаемая	попаданий	награда на пользователя
0	0.1331	0.065	0.5014	0.5041	2586	**0.2172**
50	0.1297	0.063	0.5309	0.5187	2550	**0.2204**
100	0.1240	0.056	0.5569	0.5300	2453	0.2167
200	0.1089	0.039	0.6001	0.5511	2160	0.1984
300	0.0963	0.024	0.6269	0.5678	1957	**0.1852**

Максимизировать вознаграждение удаётся без труда: предсказанное выросло с 0.501 до 0.627. Наблюдаемое на отложенной неделе тоже выросло — с 0.504 до 0.568. На этом месте обычно и заканчивают, объявляя успех.

Но это смещённая метрика, и смещение здесь принципиальное. Наблюдаемое вознаграждение считается только по тем рекомендациям, которые пользователь действительно посмотрел. Чем сильнее политика схлопывается, тем меньше у неё попаданий — с 2586 до 1957, на четверть, — и тем более отобранным становится подмножество, по которому берётся среднее. Политика, рекомендующая мало, но «безопасно», выглядит лучше, чем она есть.

Знаменатель надо фиксировать. Награда **на пользователя** — сумма досмотренного по всем попаданиям, делённая на число пользователей, — ведёт себя иначе: она растёт до 50-го шага (0.2204 против 0.2172, +1.5%), а затем монотонно падает до 0.1852, то есть **на 15% ниже исходной модели**.

Вывод, который из этого следует: RL здесь не повышает полезность рекомендаций, а перераспределяет её. Модель начинает показывать контент, который досматривают лучше, но попадает в интересы реже, и теряет на попаданиях больше, чем выигрывает на досматриваемости. Узкое окно, где выигрыш реален, лежит около полусотни шагов, то есть до того, как успевает развиться схлопывание.

Подпись взлома reward-модели

Разрыв между тем, что reward-модель обещает, и тем, что наблюдается:

шаг	обещано	наблюдается	разрыв
0	0.5014	0.5041	−0.003
50	0.5309	0.5187	+0.012
150	0.5800	0.5374	+0.043
300	0.6269	0.5678	+0.059

В начале reward-модель откалибрована — предсказанное и наблюдаемое совпадают с точностью до третьего знака. К концу она переоценивает собственные рекомендации на 0.059, и разрыв растёт монотонно. Это и есть количественная подпись эксплуатации: политика находит области, где модель вознаграждения ошибается в свою пользу, и уходит туда.

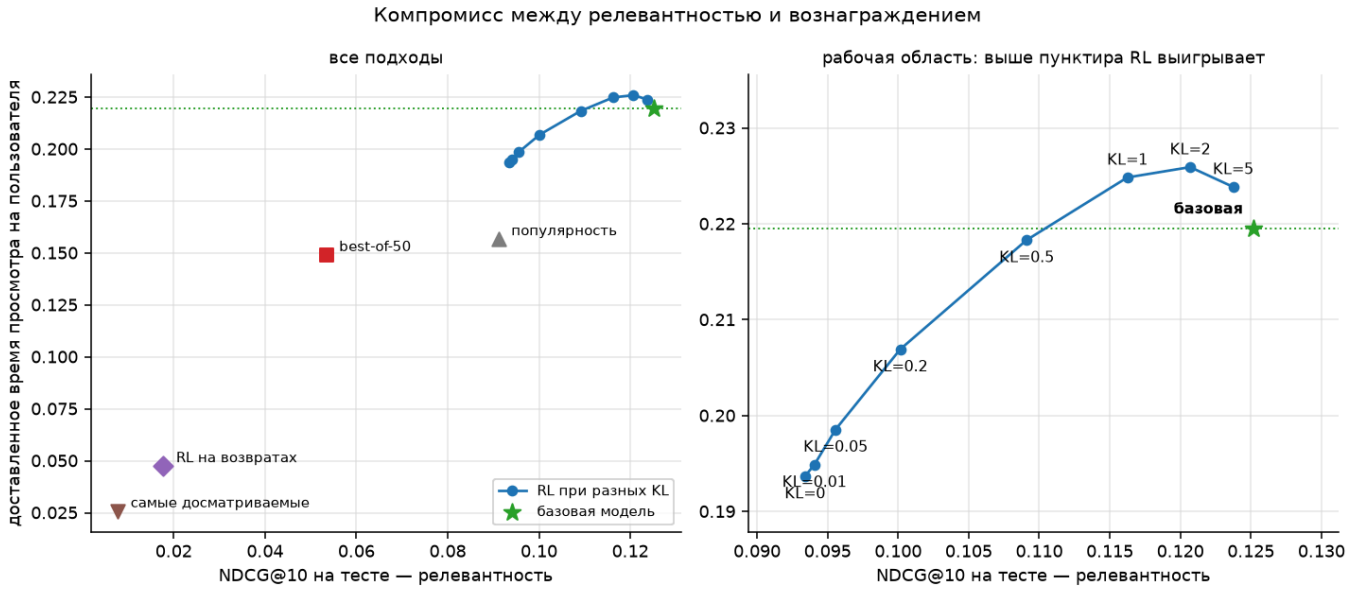
Заметить это можно только потому, что наблюдаемое вознаграждение измеряется на отложенных данных. Если смотреть на одно предсказанное вознаграждение — а именно его оптимизирует RL, — кривая выглядит как ровный успех до самого конца.

Почему схлопывание было предсказуемо

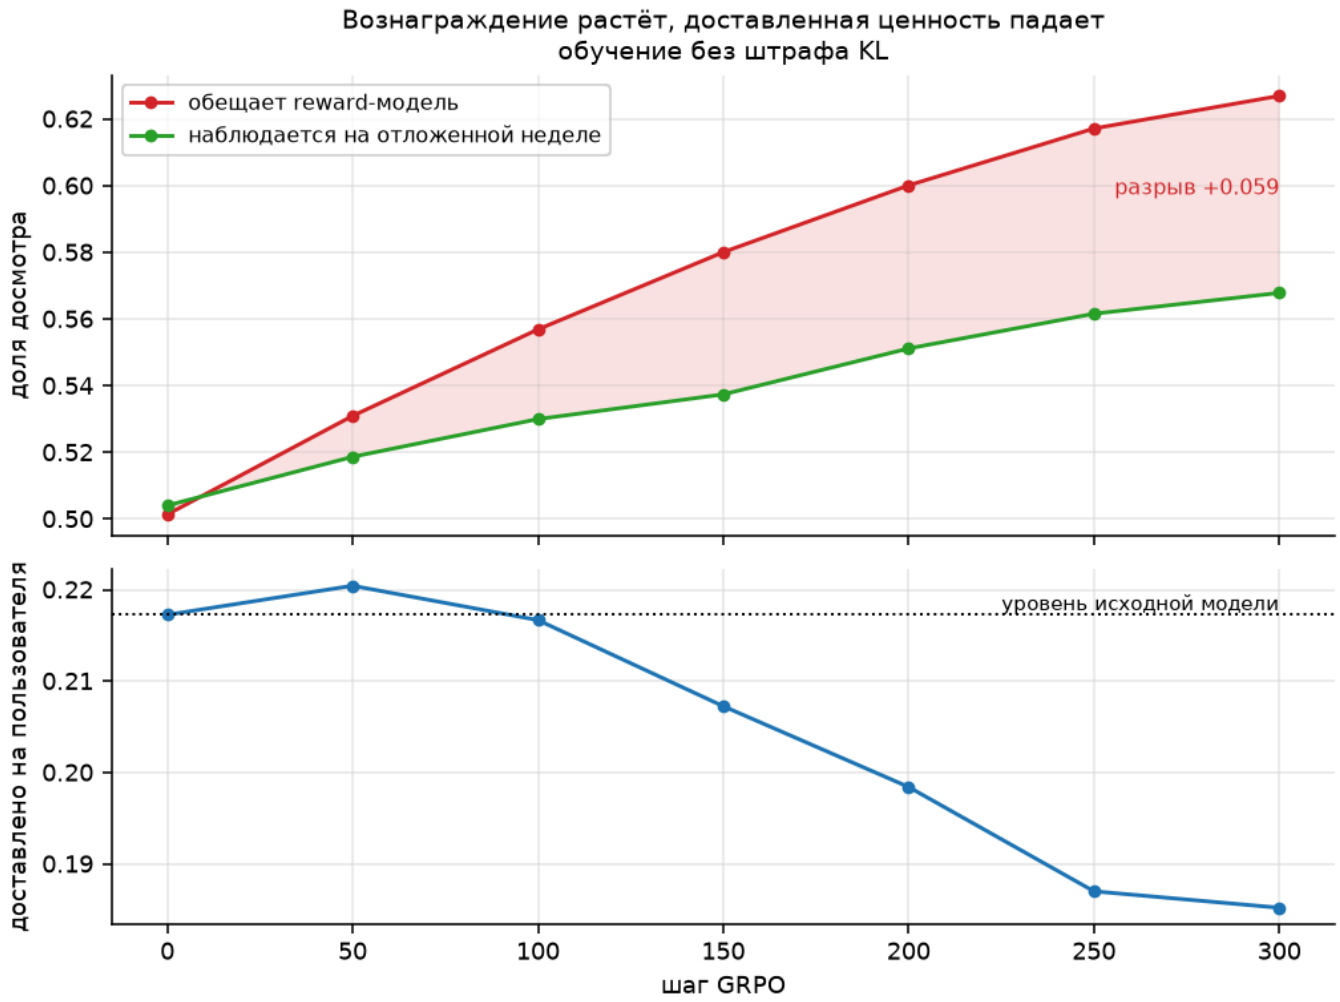
В разделе о reward-модели было сформулировано предсказание: раз 70% её сигнала определяется айтемом, а не парой, политика поедет не в сторону персонализации, а в сторону глобально досматриваемого контента.

Так и вышло. Покрытие каталога упало с 6.5% до 2.4%, то есть к концу обучения вся выдача на шесть тысяч пользователей умещается в 370 с небольшим айтемов из 15 706. Модель всё меньше отвечает на вопрос «что подойдёт этому человеку» и всё больше — на вопрос «что вообще хорошо досматривают».

Рисунки



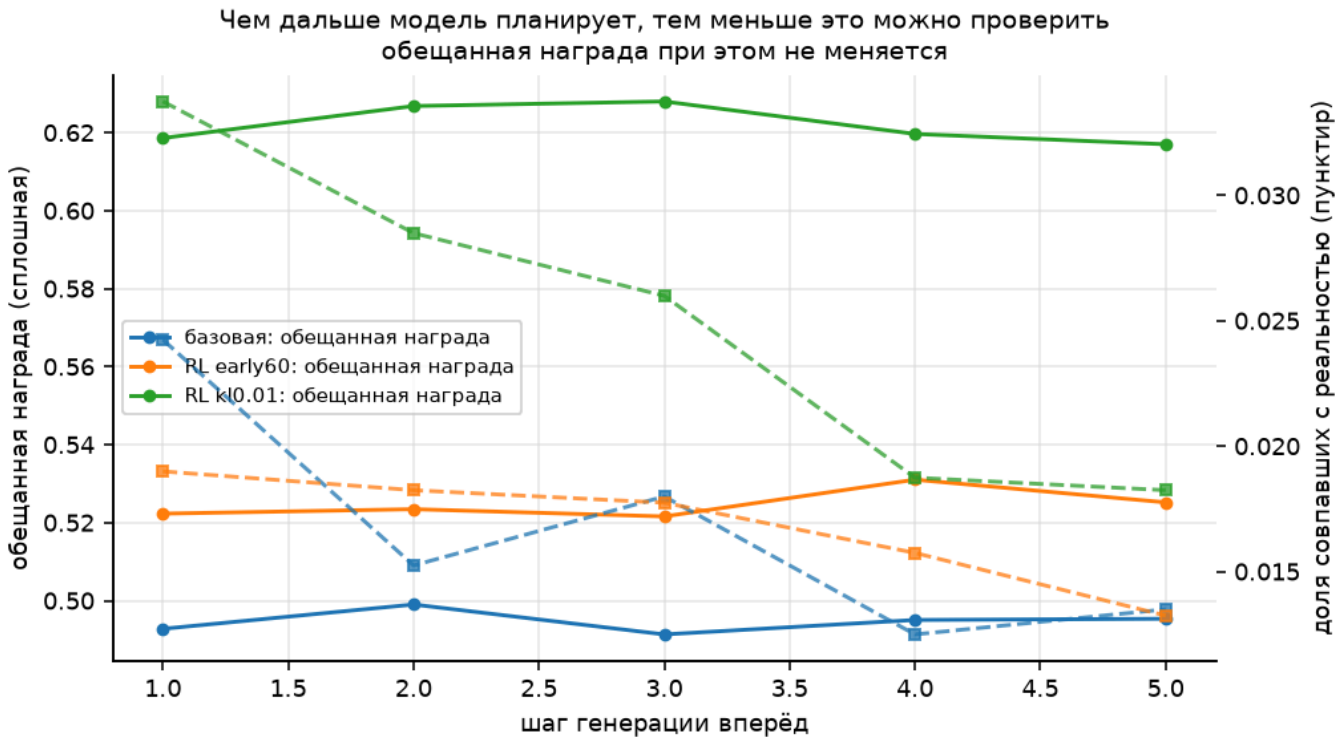
Компромисс между релевантностью и доставленной ценностью. Справа увеличена рабочая область: выше пунктира RL выигрывает у базовой модели.



Вверху — расхождение обещанного и наблюдаемого вознаграждения. Внизу — доставленная ценность: растёт до 50-го шага, затем падает ниже исходной.



Какая доля каталога остаётся в выдаче при разном штрафе KL.



При генерации вперёд обещанная награда не меняется, а доля совпавшего с реальностью падает вдвое.

Компромисс между релевантностью и вознаграждением

Коэффициент KL оказался не настройкой, а главным параметром задачи. Итог на тесте, 20 000 пользователей (полная таблица — в разделе результатов):

коэффициент KL	NDCG@10	покрытие	доставлено на пользователя
базовая модель	0.1252	0.089	0.2195
5	0.1237	0.086	0.2239
2	**0.1207**	0.084	**0.2259**
1	0.1162	0.075	0.2248
0.5	0.1091	0.062	0.2183
0.2	0.1002	0.046	0.2069
0.05	0.0956	0.039	0.1986
0	0.0934	0.037	0.1937

Кривая немонотонна и имеет максимум. Выше базовой модели по доставленной ценности поднимаются только прогоны с KL от 1 до 5; всё, что слабее, уходит и по релевантности, и по ценности одновременно.

Лучшая точка: +2.9% доставленного времени просмотра ценой −3.6% релевантности. Это честный, но скромный размен, и важно, что он вообще существует: наивная оптимизация того же вознаграждения даёт −12% ценности.

Это не шум

Прогон с KL = 2 повторён с четырьмя разными сидами:

сид	NDCG@10	доставлено на пользователя
42	0.1207	0.2259
1	0.1204	0.2252
2	0.1209	0.2261
3	0.1208	0.2252

Размах по сидам 0.0009, прирост над базовой моделью 0.0061 — в семь раз больше. Эффект устойчив.

Стандартные для RLHF значения KL здесь не работают

В работах по дообучению языковых моделей коэффициент KL обычно берут в диапазоне от 0.01 до 0.1. В этой задаче весь такой диапазон лежит глубоко в области схлопывания: при 0.05 покрытие падает с 8.9% до 3.9% каталога, а доставленная ценность — на 10%. Рабочая область начинается на два порядка выше.

Объяснение в структуре задачи. У языковой модели словарь в десятки тысяч токенов, но распределение следующего токена сильно ограничено грамматикой и смыслом — уйти далеко мешает сам язык. У рекомендателя ничто не мешает перенести всю массу на десяток «хорошо досматриваемых» позиций: любой айтем из 15 706 — синтаксически допустимое продолжение. Удерживать политику приходится почти исключительно штрафом, и поэтому он нужен на порядки сильнее.

Жадная оптимизация вознаграждения без ограничения

Самый дешёвый способ поднять вознаграждение — не обучать ничего, а переранжировать: взять топ-50 базовой модели и отсортировать его reward-моделью. Я ожидал, что этот приём обесценит всю RL-часть.

Вышло наоборот. Best-of-50 поднимает предсказанное вознаграждение до 0.670 — выше, чем любой прогон RL, — но обрушивает NDCG с 0.1252 до 0.0534, то есть на 57%, и доставленную ценность до 0.1491, на 32% ниже базовой модели.

Это меняет интерпретацию всей работы. Ценность RL здесь **не в самой оптимизации вознаграждения** — оптимизировать его тривиально и это вредно. Ценность в том, что KL-штраф даёт регулируемый способ забрать часть выигрыша, не уходя далеко от исходной политики. Без такого ограничения любой метод, максимизирующий это вознаграждение, разрушает рекомендации.

Предельная точка того же направления — строка «самые досматриваемые»: показать всем один и тот же список из десяти наиболее досматриваемых позиций каталога. Предсказанное вознаграждение рекордное, 0.779, доставленная ценность — 0.0258, то есть в восемь раз ниже базовой модели. Оптимум модели вознаграждения находится ровно там, и чем ближе к нему, тем хуже рекомендации.

Что меняется в поведении модели

Помимо чисел, меняется состав выдачи:

подход	доля сериалов	покрытие каталога
базовая модель	0.32	0.089
RL, KL = 2	0.24	0.084
RL, KL = 0	0.16	0.037
best-of-50	0.05	0.065
самые досматриваемые	0.00	0.001

Оптимизация доли досмотра систематически вытесняет сериалы, и причина проверяется прямо по данным:

тип контента	событий	средняя доля досмотра	доля полных досмотров
фильмы	4 137 134	51.2%	38.2%
сериалы	1 339 117	31.6%	14.5%

У сериала доля просмотра считается по эпизоду, и досматривают его в полтора раза реже. Модель вознаграждения это добросовестно выучила, а политика добросовестно этим воспользовалась — и стала рекомендовать то, что удобнее досматривать, а не то, что человек хочет смотреть. Никакой ошибки в reward-модели здесь нет: она права насчёт доли досмотра. Ошибка в том, что доля досмотра была назначена целью.

Это и есть ответ на вопрос «чем рекомендации дообученной модели отличаются от исходных» в наиболее конкретной форме, какую позволяют данные.

Многошаговая генерация

Задание спрашивает, что происходит, если генерировать несколько рекомендаций подряд, каждый раз добавляя сгенерированное в контекст. Ответ упирается в одну вещь: начиная со второго шага модель рассуждает об истории, которой не было. Пользователь не смотрел то, что ему порекомендовали на первом шаге — это пока только рекомендация.

Проверить сгенерированный шаг можно единственным честным способом: посмотреть, попал ли этот айтем в то, что пользователь действительно посмотрел на отложенной неделе. Эта доля и падает по мере удаления от реальности, тогда как оценка модели вознаграждения не меняется совсем.

модель	шаг	обещанная награда	совпало с реальностью	разных айтемов
базовая	1	0.4928	0.0243	1541
базовая	3	0.4914	0.0180	1577
базовая	5	0.4954	**0.0135**	1587
RL, KL = 0.01	1	0.6187	0.0338	838
RL, KL = 0.01	3	0.6281	0.0260	764
RL, KL = 0.01	5	0.6171	**0.0182**	830

К пятому шагу проверяемость падает примерно вдвое у обеих моделей, а обещанная награда держится на том же уровне до третьего знака. Модель вознаграждения никак не сигнализирует, что работает по выдуманному контексту: она одинаково уверенно оценивает и первый шаг, где контекст настоящий, и пятый, где четыре из последних пяти событий модель придумала сама.

Практическое следствие для RL: если строить вознаграждение по многошаговым траекториям — а это естественный способ учесть долгосрочность, — то оптимизация будет вестись по числу, которое на дальних шагах не проверяется ничем. Накопление ошибки здесь не шумное, а молчаливое, и обнаружить его по самому вознаграждению невозможно.

Отдельно стоит отметить строку с числом разных айтемов: схлопнувшаяся политика (KL = 0.01) выдаёт вдвое меньше различных позиций на каждом шаге, 838 против 1541, и это не выправляется с глубиной генерации.

Долгосрочные цели

Доля досмотра — сигнал внутри одного контакта. Задание спрашивает, можно ли сформулировать вознаграждение, поощряющее возвращение пользователя.

На KION для этого есть ровно один честно считаемый офлайн-сигнал: была ли у пользователя хоть одна активность в течение семи дней после события. Базовая частота 64.4%. Корреляция этого сигнала с «досмотрел не меньше половины» на полных данных составляет **−0.002**, то есть они статистически независимы.

Это само по себе содержательный результат: **максимизация доли досмотра не приближает к удержанию, потому что движет модель вдоль оси, ортогональной ему.** Любые рассуждения вида «будем оптимизировать досматриваемость, и люди станут возвращаться» на этих данных не подтверждаются.

Модель, предсказывающая возврат, при этом получилась лучше модели досмотра по одному важному признаку — она действительно персонализирована:

модель вознаграждения	**превосходство над справочником «среднее по айтему»**
доля досмотра	AUC 0.683 против 0.674 (+0.009)
возврат за 7 дней	AUC 0.687 против 0.598 (**+0.089**)

То есть возврат в десять раз сильнее зависит от пары «пользователь — айтем», а не от одного айтема. Казалось бы, это лучший кандидат в цель для RL.

Результат оказался противоположным ожиданию, и это главная неудача работы. RL против модели возвратов обрушил NDCG@10 с 0.1252 до 0.0177, то есть в семь раз, а доставленное время просмотра — с 0.2195 до 0.0475. Покрытие при этом осталось высоким (0.090): политика не схлопнулась в популярное, она просто перестала попадать в интересы.

Объяснение, которое согласуется со всеми наблюдениями: «вернётся ли пользователь в течение недели» — это преимущественно свойство **пользователя**, а не рекомендации. Модель хорошо предсказывает возврат, потому что считывает из истории, насколько человек вообще активен. Но градиент политики от этого не получает полезного направления: почти любая рекомендация активному пользователю даёт высокое предсказание, а неактивному — низкое, и оптимизация вырождается.

Сигнал, который хорошо **предсказывается**, не обязан быть сигналом, который хорошо **оптимизируется**. Для RL нужна не точность reward-модели, а её чувствительность к тому, чем политика может управлять. Эту разницу стоит проверять до запуска обучения, и измерить её несложно: достаточно посмотреть, какая доля разброса предсказаний объясняется айтемом, а какая — пользователем.

Что можно проверить офлайн, а что нельзя

Офлайн проверяется: меняется ли состав выдачи, падает ли релевантность, схлопывается ли каталог, растёт ли разрыв между обещанным и наблюдаемым вознаграждением. Всё это сделано выше.

Офлайн **не** проверяется главное: вырастет ли удержание на самом деле. Сигнал «вернулся через неделю» фиксирует корреляцию, а не следствие рекомендации — человек мог вернуться по десятку причин, никак с ней не связанных. Разделить их можно только онлайн-экспериментом с разделением трафика и достаточно долгим горизонтом наблюдения, потому что эффект на удержание проявляется на масштабе недель, а не одного сеанса.

Ограничения

Дневные таймстемпы. 30.2% пользовательских дней содержат больше одного события, в среднем 2.84. То есть примерно треть порядка внутри «последовательности» неизвестна, и внутри дня события упорядочены произвольно. Для последовательной модели это ощутимый шум, и часть потолка качества базовой модели объясняется именно им, а не архитектурой.

Размер модели. GPT-2 на 2.8 млн параметров, контекст 32 айтема, обучение на процессоре. Это сознательный выбор под доступное железо, а не оптимум. Более крупная модель дала бы более высокий старт, и не факт, что выводы про RL перенеслись бы без изменений: чем лучше базовая политика, тем, вероятно, больше ей есть что терять.

Один датасет и один домен. Все выводы получены на KION. Отсутствие повторного потребления — структурная особенность именно этой выгрузки, и на музыкальном датасете, где повторы составляют основную массу событий, типичный способ взлома reward-модели был бы совсем другим.

Reward-модель посредственная. Spearman 0.372 на отложенной выборке и превосходство над справочником по айтему всего на 0.02. Часть эффектов, описанных как «взлом», может оказаться просто следствием её слабости. Проверить это можно было бы более сильной моделью вознаграждения, и это первое, что стоит сделать дальше.

Горизонт возврата выбран произвольно. Семь дней взяты как разумный срок, но ни трое суток, ни две недели не проверялись. Вывод о независимости досмотра и возврата получен при одном значении горизонта.

RL короткий. 300 шагов GRPO с батчем 64, то есть политика видела порядка 20 000 контекстов из 240 000 доступных. Более длинное обучение при большом KL могло бы сместить оптимум; при малом KL, судя по траекториям, оно лишь усугубило бы схлопывание.

Доверительные интервалы не считались. Устойчивость ключевого результата проверена разбросом по четырём сидам (размах в семь раз меньше эффекта), но парный бутстрэп по пользователям, как в первом задании, здесь не делался.

Воспроизведение

```
python -m venv .venv && . .venv/bin/activate     # python 3.12
pip install -r requirements.txt
./run_all.sh
```

Полный прогон на восьмиядерном процессоре занимает около двух с половиной часов, из них примерно 35 минут — базовая модель, по 15 минут каждая из двух моделей вознаграждения, по 2–3 минуты на прогон RL.

Отдельные шаги:

```
python scripts/prepare_sequences.py       # события -> последовательности, словарь
python tests/test_no_leakage.py           # шесть тестов на утечки
python scripts/train_sft.py --epochs 4    # базовая GPT-2
python scripts/train_reward.py            # вознаграждение: доля досмотра
python scripts/diagnose_reward.py         # сколько в ней персонализации
python scripts/train_return_reward.py     # вознаграждение: возврат за 7 дней
python scripts/train_rl.py --kl 2.0       # GRPO
python scripts/evaluate_all.py            # единственный скрипт, читающий тест
python scripts/analyze_rollout.py         # многошаговая генерация
python scripts/make_figures.py && python scripts/make_report.py
```

Данные берутся из подготовленного parquet первого задания (`../tlab-recsys/data`); если его нет, `scripts/prepare_sequences.py` ожидает `events.parquet` и `items.parquet` в каталоге `data` .

Структура репозитория

```
src/rlrec/
  config.py     даты разбиения, размер контекста, служебные токены
  data.py       последовательности, окна обучения, примеры для reward-моделей
  model.py      GPT-2-политика и модель вознаграждения
  rl.py         GRPO: группа кандидатов, преимущество, KL ко всему распределению
  evaluate.py   ранжирующие метрики, метрики каталога, доставленная ценность
scripts/        по одному на каждый этап
tests/          шесть тестов на утечки
runs/           результаты прогонов в JSON и чекпойнты
reports/        рисунки и разделы отчёта
```